Báo cáo bài tập thực hành 1

CLUSTERING

Trịnh Mẫn Hoàng - 14520320

GV: TS. Lê Đình Duy
Môn học: Máy học trong thị giác máy tính

Mục Lục

Mục Lục Ảnh **2**

I. Giới thiệu bài toán clustering **3**

a. Input *3*

b. 2 Output *3*

II. Giới thiệu thuật toán **3**

a. Kmeans clustering [1] *3*

i. Ý tưởng: 3

ii. Các bước thực hiện 3

b. Spectral clustering [2] *3*

i. Ý tưởng 3

ii. Các bước thực hiện: 3

c. DBSCAN [3] *4*

i. Ý tưởng 4

ii. Các bước thực hiện 4

d. Agglomerative [4] *4*

i. Ý tưởng 4

ii. Các bước thực hiện 4

III. Thực nghiệm [5] **5**

Link Github: https://github.com/HoangTrinh/Machine-Leaning-in-Computer-Vision.git *5*

a. Dùng dữ liệu point tự tạo. *5*

i. Dữ liệu: 5

ii. Kết quả: 5

b. Dùng bộ dữ liệu chữ số viết tay *6*

i. Dữ liệu 6

ii. Kết quả 6

iii. Đánh giá và so sánh 6

c. Dùng bộ dữ liệu face *6*

i. Dữ liệu 6

ii. Các bước thực hiện 6

iii. Kết quả 7

iv. Đánh giá và so sánh 7

d. Dùng bộ dữ liệu tự chọn *7*

i. Dữ liệu 7

ii. Các bước thực hiện: 7

iii. Kết quả 8

iv. Đánh giá và so sánh 8

Tài Liệu Tham Khảo **9**

Mục Lục Ảnh

Figure 1 - Hand digits clustering result 6
Figure 2 - face clustering result 7
Figure 3 - Car clustering result 8

I. Giới thiệu bài toán clustering

a. Input

- Tập dữ liệu không dán nhãn

b. 2 Output

- Tập dữ liệu đã được phân chia thành các cụm (cluster)
- Dữ liệu trong cùng một cluster có tính chất giống nhau

II. Giới thiệu thuật toán

a. Kmeans clustering [1]

i. Ý tưởng:

- Tìm cách phân nhóm các đối tượng (objects) đã cho vào K cụm (K là số các cụm được xác đinh trước, K nguyên dương) sao cho tổng bình phương khoảng cách giữa các đối tượng đến tâm nhóm (centroid) là nhỏ nhất.

ii. Các bước thực hiện

- Bước 1:
  Chọn ngẫu nhiên K tâm (centroid) cho K cụm (cluster). Mỗi cụm được đại diện bằng các tâm của cụm.
- Bước 2:
  Tính khoảng cách giữa các đối tượng (objects) đến K tâm (thường dùng khoảng cách Euclidean)
- Bước 3:
  Nhóm các đối tượng vào nhóm gần nhất
- Bước 4:
  Xác định lại tâm mới cho các nhóm (dùng means hoặc median)
- Bước 5:
  Thực hiện lại bước 2 cho đến khi không có sự thay đổi nhóm nào của các đối tượng (hội tụ)

b. Spectral clustering [2]

i. Ý tưởng

- Tìm cách đưa các đối tượng về dạng đồ thị tương đồng, sau đó dùng k dimensions để phân hoạch đồ thị

ii. Các bước thực hiện:

- Bước 1:
  Chọn hàm tính độ tương đồng kenel(x,y)
- Bước 2:
  Xây dựng đồ thị với mỗi node là một đối tượng và các cạnh chứa giá trị tương đồng wij = kernel(Xi,Xj)

- Bước 3:
  Tính toán đồ thị Laplacian: L = D - W
  Trong đó : D là ma trận đường chéo của ma trận G (Ma trận kề của W), với dij=deg[i]
- Bước 4:
  Tìm eigenvector e tương ứng với eigenvalue nhỏ thứ hai cho một trong hai phương trình sau:
  Lf = Lamda*D*f normalized
  Lf = Lamda*f unnormalized
- Bước 5:
  Kết luận các nhóm được phân hoạch dựa trên eigenvalue

c. DBSCAN [3]

i. Ý tưởng

- Gom nhóm các điểm chứa lẫn nhau và chứa đủ nhiều hơn một ngưỡng, nếu thấp hơn ngưỡng, xem như là một noise.

ii. Các bước thực hiện

- Bước 1:
  Tìm số lượng neighbors cho mỗi điểm trong một phạm vi eps, chọn các điểm có số lượng neighbors >= minPTs (định trước) làm core point
- Bước 2:
  Tìm tất cả các điểm có liên kết với core points trong đồ thị biểu diễn neighbors, bỏ qua các điểm non-core
- Bước 3:
  Đưa các điểm non-core vào cluster gần nhất trong phạm vi ép, nếu không có, xem như là noise.

d. Agglomerative [4]

i. Ý tưởng

- Đi từ bottom-up, gom nhóm các clusters gần nhau nhất cho đến khi chỉ còn 1 cluster

ii. Các bước thực hiện

- Bước 1:
  Xem mỗi đối tượng là 1 cluster
- Bước 2:
  Tính khoảng cách từng đôi một giữa các cluster
- Bước 3:
  Tạo một ma trận khoảng cách từ bước 2
- Bước 4:
  Tìm cặp cluster có khoảng cách ngắn nhất
- Bước 5:

Xóa cặp trên ra khỏi ma trận và nhóm lại

- Bước 6:

  Tính khoảng cách từ cluster mới tới các cluster đã biết, cập nhật ma trận

- Bước 7:

  Lặp lại bước 4 cho đến khi ma trận chỉ còn một phần tử

III. Thực nghiệm [5]

Link Github: https://github.com/HoangTrinh/Machine-Leaning-in-Computer-Vision.git

a. Dùng dữ liệu point tự tạo.

i. Dữ liệu:

- Tạo random 750 điểm dữ liệu dùng hàm mat_blobs của sklearn.datasets, chia làm 2 Gaussians

ii. Kết quả:

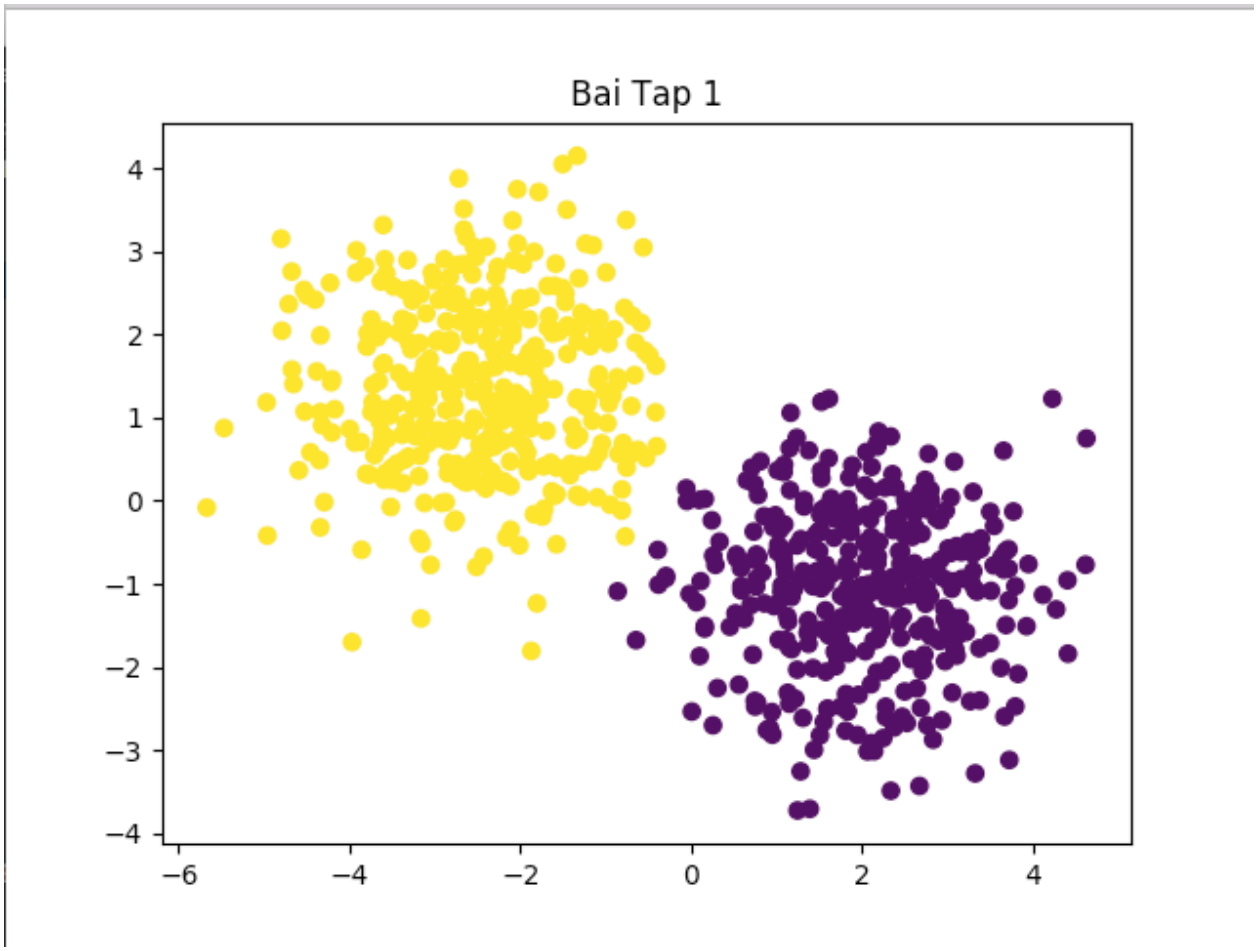

b. Dùng bộ dữ liệu chữ số viết tay

i. Dữ liệu

- Dùng bộ dữ liệu lấy được từ hàm load_digits của sklearn.datasets, bao gồm 10 nhóm khác nhau

ii. Kết quả

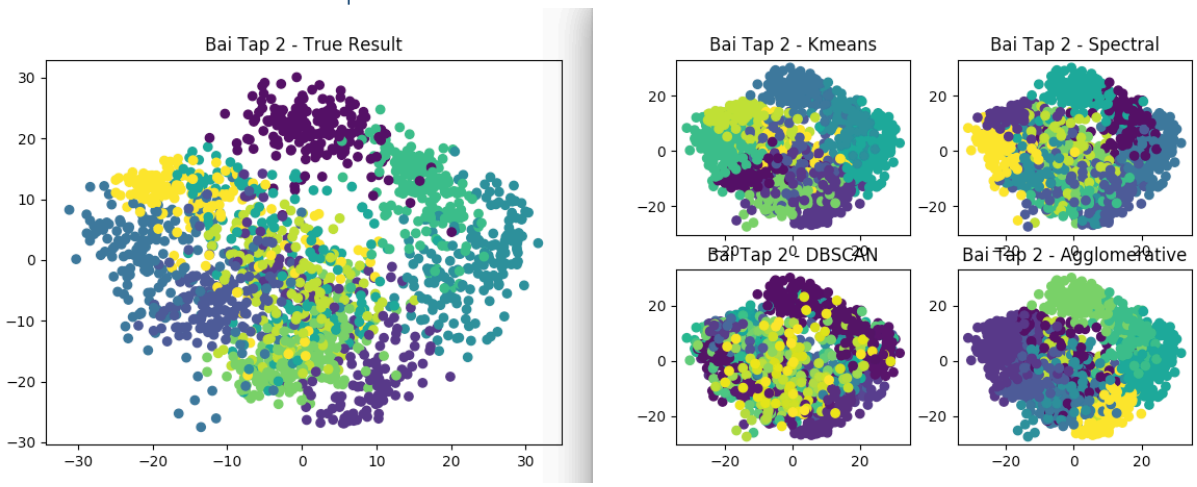

Figure 1 - Hand digits clustering result

iii. Đánh giá và so sánh

- Các thuật toán cho kết quả gần tương đồng với kết quả thực
- Kmeans và Agglomerative không thể xử lý các trường hợp ouliner (vị trí (-10,-20) và xung quanh vị trí (0,0) nơi có một vài điểm thuộc cluster khác)
- DBSCAN có xu hướng xem các điểm tại rìa là noise
- Spectral là thuật giải mang lại kết quả gần như tốt nhất trong cả 4 thuật giải đã cài đặt trong trường hợp này

c. Dùng bộ dữ liệu face

i. Dữ liệu

- Dùng bộ dữ liệu lấy được từ hàm fetch_lfw_people của sklearn.datasets, mỗi nhóm sẽ có trên 40 ảnh, giảm size ảnh xuống còn 40% so với ảnh gốc.
- Dùng Local Binary Pattern [6] để xử lý
- Vì không biết rõ số lượng nhóm thực của ảnh nên ta sẽ nhóm một cách tượng trưng là 7 nhóm

ii. Các bước thực hiện

- Bước 1:

  Load ảnh từ bộ dữ liệu
- Bước 2:

Dùng hàm local_binary_pattern thuộc thư viện skimage để trích xuất đặc trưng LBP

- Bước 3:

  Lưu tập features được trích xuất dưới dạng file numpy: data.npy
  Lưu kết quả đúng được thư viện hỗ trợ dưới dạng file numpy: target.npy

- Bước 4:

  Mỗi khi chạy chương trình: Load hai file: data.npy, target.npy

- Bước 5:

  Dùng các thuật giải để phân cụm dữ liệu trên, visualize kết quả, xem xét, đánh giá kết quả

iii. Kết quả

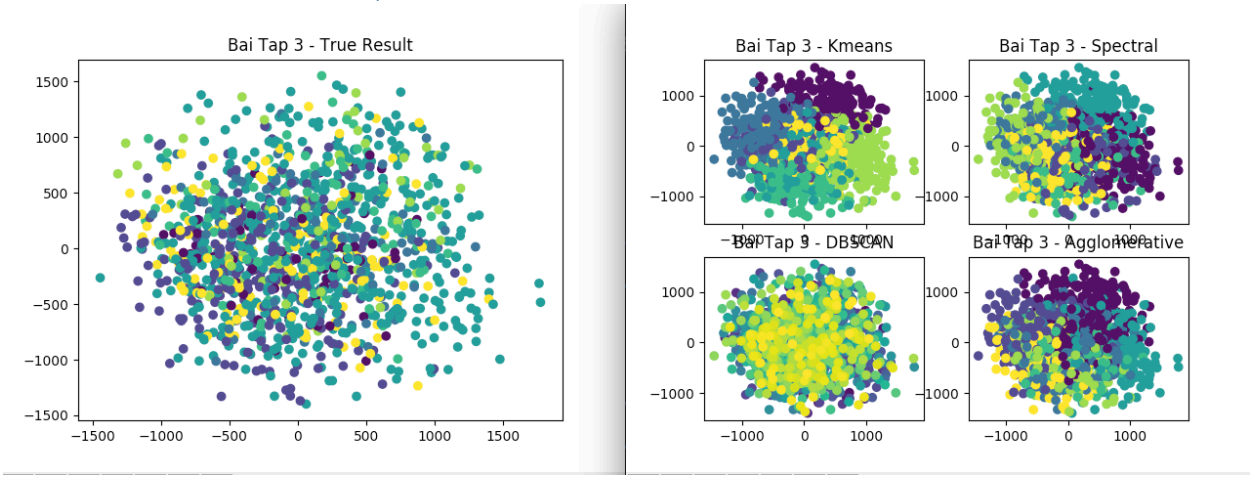

Figure 2 - face clustering result

iv. Đánh giá và so sánh

- Có sự sai khác rất lớn giữa Kmeans, Spectral và Agglomerative so với kết quả thực
- Vì dữ liệu phân tán đều nên các thuật toán phân cụm dựa vào khoảng cách tương đối thường cho kết quả sai
- DBSCAN mang lại kết quả dễ chấp nhận nhất nhờ khả năng lan truyền

d. Dùng bộ dữ liệu tự chọn

i. Dữ liệu

- Dùng tập train thuộc bộ dữ liệu cars dataset của stanford university, bao gồm 8144 ảnh, được resize(50,75), chia 196 nhóm. [7] [8]
- Dùng Histogram of Oriented Gradients [6] để xử lý

ii. Các bước thực hiện:

- Bước 1:

  Load ảnh từ bộ dữ liệu đặt cùng thư mục

- Bước 2:
  Dùng hàm hog thuộc thư viện skimage để trích xuất đặc trưng HOG
- Bước 3:
  Lưu tập features được trích xuất dưới dạng file numpy: data.npy
- Bước 4:
  Mỗi khi chạy chương trình: Load hai file: data.npy
- Bước 5:
  Dùng các thuật giải để phân cụm dữ liệu trên, visualize kết quả, xem xét, đánh giá kết quả

iii. Kết quả

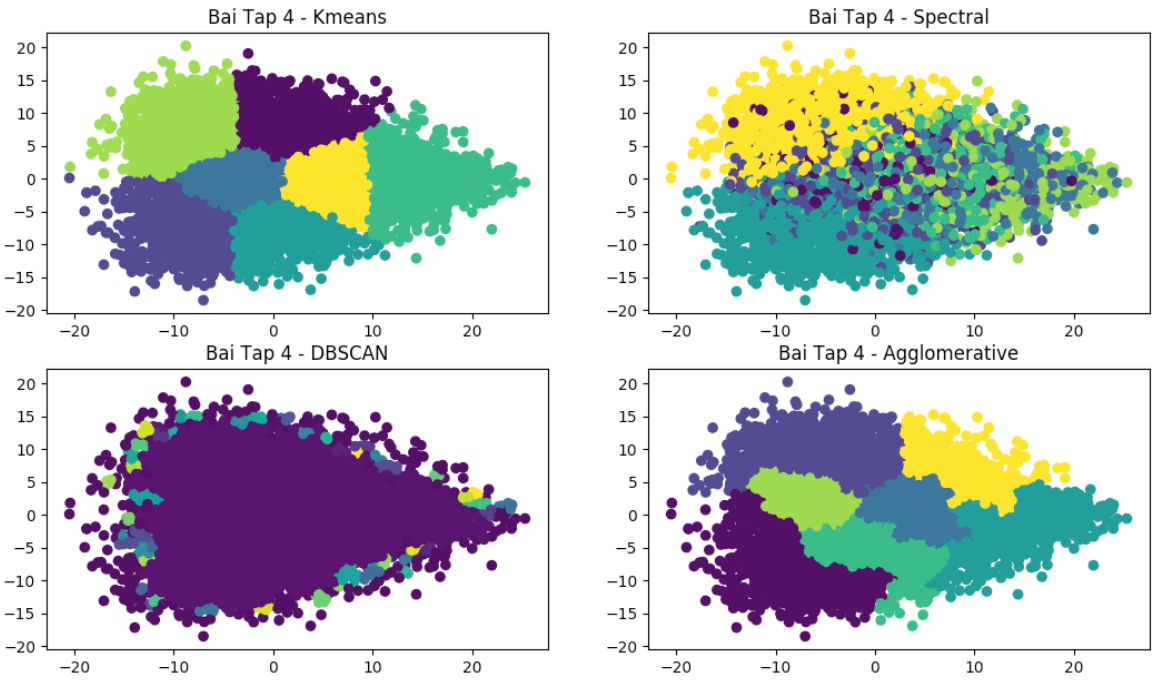

Figure 3 - Car clustering result

iv. Đánh giá và so sánh

- Vì dữ liệu chuẩn không hỗ trợ python nên chỉ đánh giá sự khác biệt giữa các thuật toán
- Có thể thấy, với bộ dữ liệu mang tính dày đặc,DBSCAN cho kết quả rất tệ, đặc biệt ở phần trung tâm
- Kmeans và Agglomarative có khuynh hướng nhóm các tập điểm về dạng spherical.
- Spectral vừa có thể gom các điểm ở gần cũng như xử lý các điểm outliner khá tốt

Tài Liệu Tham Khảo

[1] V. H. Tiệp, "machinelearningcoban.com," [Online]. Available: https://machinelearningcoban.com/2017/01/01/kmeans/.

[2] M. B. O. B. Ulrike von Luxburg, "Consistency of Spectral Clustering," [Online]. Available: http://web.cse.ohio-state.edu/~belkin.8/papers/SC_AOS_07.pdf.

[3] "Wikipedia," 25 9 2017. [Online]. Available: https://en.wikipedia.org/wiki/DBSCAN.

[4] "mprovedoutcomes," [Online]. Available: http://www.improvedoutcomes.com/docs/WebSiteDocs/Clustering/Agglomerative_Hierarchical_Clustering_Overview.htm.

[5] "scikit-learn.org," [Online]. Available: http://scikit-learn.org/stable/modules/clustering.html#clustering.

[6] "scikit-image.org," [Online]. Available: http://scikit-image.org/docs/stable/api/skimage.feature.html.

[7] "http://ai.stanford.edu/," [Online]. Available: http://ai.stanford.edu/~jkrause/cars/car_dataset.html.

[8] M. S. J. D. L. F.-F. Jonathan Krause, " 3D Object Representations for Fine-Grained Categorization," *ICCV 2013 (3dRR-13),* 8 12 2013.

[9] "Wikipedia," [Online]. Available: https://en.wikipedia.org/wiki/Histogram_of_oriented_gradients.